Metriche di valutazione

Appunti · rete spiking balena / non balena

Numeri di esempio usati in tutti gli appunti: test set di 500 clip, 139 con balena e 361 senza. Vengono da una prova dello script su dati sintetici.

Dagli spike alla risposta

La rete ha 2 neuroni di uscita, uno "balena" e uno "non balena". Durante il clip ognuno spara un certo numero di volte.

> punteggio balena = spike balena / (spike balena + spike non balena)

Va da 0 a 1. Esempio: 8 spike balena e 2 non balena danno 8 / 10 = 0,8. Se nessuno dei due spara, si usa il potenziale di membrana come spareggio.

Risposta: se punteggio ≥ soglia allora "balena", altrimenti "non balena". ROC-AUC e PR-AUC usano il punteggio e non dipendono dalla soglia; tutte le altre metriche sì.

Insiemi di dati: il **training** serve ad addestrare, il **validation** a scegliere la soglia e gli iperparametri, il **test** a misurare le prestazioni una volta sola alla fine.

Matrice di confusione

Ogni clip finisce in una di quattro caselle. Positivo = la rete dice balena.

	La rete dice: BALENA	La rete dice: NON BALENA
Balena reale	**VP**, vero positivo: balena trovata	**FN**, falso negativo: balena persa
Nessuna balena	**FP**, falso positivo: falso allarme	**VN**, vero negativo: silenzio corretto

	Predetto balena	Predetto non balena	Totale
Balena reale	VP = 110	FN = 29	139
Non balena reale	FP = 41	VN = 320	361
Totale	151	349	500

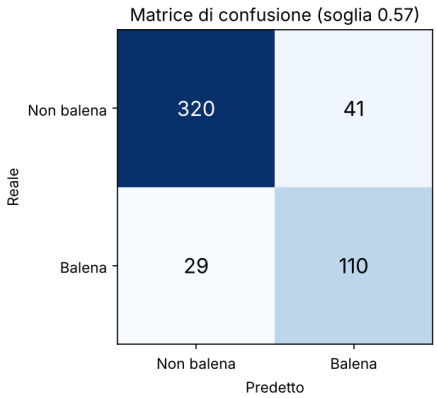


Figura 1 · confusion_matrix.png

FN = balena persa, l'errore più grave per il monitoraggio. FP = falso allarme, costa tempo di ricontrollo.

Metriche a soglia fissata

Accuracy

Cosa misura: la quota di risposte giuste sul totale.

> Accuracy = (VP + VN) / totale = (110 + 320) / 500 = **0,860**

Esempio: 86% di risposte giuste.

Quando conta: da sola dice poco quando le classi sono sbilanciate. Chi risponde sempre "non balena" fa già 361 / 500 = 0,722 senza trovare nessuna balena. Va sempre confrontata con questo valore (lo script lo fa).

Recall (sensibilità)

Cosa misura: quante delle balene presenti vengono trovate.

> Recall = VP / (VP + FN) = 110 / 139 = **0,791**

Esempio: trovate 110 balene su 139; il 21% viene perso.

Quando conta: è la metrica più importante se l'obiettivo è non perdere balene.

Precision

Cosa misura: quante delle risposte "balena" sono corrette.

> Precision = VP / (VP + FP) = 110 / 151 = **0,728**

Esempio: 151 allarmi, 110 veri; il 27% sono falsi allarmi.

Quando conta: conta se ogni allarme costa qualcosa, per esempio un controllo manuale.

Specificità

Cosa misura: quanti dei clip senza balena vengono riconosciuti come tali (è la recall della classe "non balena").

$$\text{Specificità} = VN / (VN + FP) = 320 / 361 = \mathbf{0,886}$$

Esempio: 320 clip vuoti su 361 classificati correttamente.

Balanced accuracy

Cosa misura: l'accuracy con le due classi pesate allo stesso modo, qualunque sia la loro frequenza.

$$\text{Balanced accuracy} = (\text{Recall} + \text{Specificità}) / 2 = (0,791 + 0,886) / 2 = \mathbf{0,839}$$

Esempio: 0,839. Chi risponde sempre "non balena" ottiene esattamente 0,5.

Quando conta: sostituisce l'accuracy quando le classi sono sbilanciate.

F1

Cosa misura: un solo numero che combina precision e recall (media armonica): è alta solo se lo sono entrambe.

$$F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall}) = \mathbf{0,759}$$

Esempio: 0,759. Chi risponde sempre "balena" ha recall 1 ma precision 0,28 e F1 = 0,43.

F-beta: F1, F0.5 e F2

La F1 è un caso particolare della F-beta. Il parametro beta decide quanto pesa la recall rispetto alla precision.

$$F_\beta = (1 + \beta^2) \times \text{Precision} \times \text{Recall} / (\beta^2 \times \text{Precision} + \text{Recall})$$

Metrica	Cosa privilegia	Adatta se
F0.5	Precision (la recall pesa la metà)	i falsi allarmi sono costosi, es. ogni allarme va ricontrollato a mano
F1	Equilibrio	i due errori pesano uguale
F2	Recall (pesa il doppio)	perdere una balena è peggio di un falso allarme, es. monitoraggio di specie protette

Usare la F0.5 non è sbagliato, ma è una scelta: dice che preferiamo pochi falsi allarmi a costo di perdere balene. Il punto delicato è che la F-beta usata per **scegliere la soglia** cambia molto il comportamento della rete. Stessa rete, tre soglie scelte sul validation set con tre F diverse:

Soglia scelta con	Soglia	Precision	Recall	F0.5	F1	F2
F0.5	0,80	0,910	**0,439**	0,749	0,592	0,490
F1	0,57	0,729	0,791	0,740	0,759	0,778
F2	0,43	0,591	0,892	0,633	0,711	0,809

Con la F0.5 la precision sale al 91% ma la recall scende al 44%: più di metà delle balene viene persa. Per un sistema che deve trovare balene la F0.5 di solito non è adatta; la F1 o la F2 lo sono di più. In ogni caso la scelta va motivata nella relazione. Nello script: opzione `--beta` (default 1); F1, F0.5 e F2 vengono comunque riportate tutte.

La soglia

Soglia alta: meno falsi allarmi, più balene perse. Soglia bassa: il contrario. Si sceglie sul validation set (massimizzando la F-beta scelta) e si applica invariata al test set; sceglierla sul test set gonfierebbe i risultati.

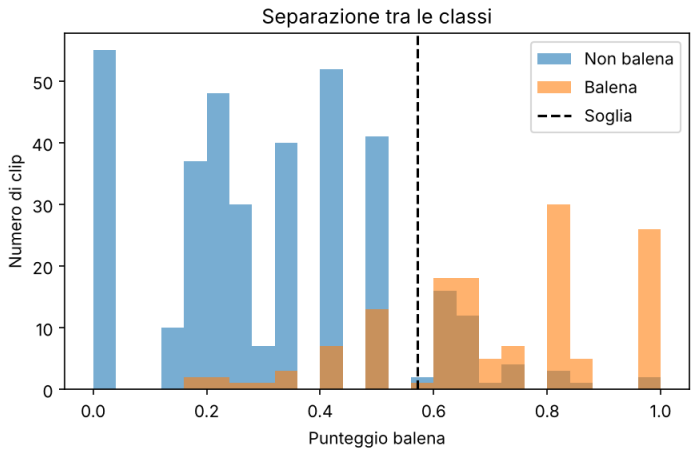


Figura 2 · score_distribution.png. Blu: clip senza balena; arancione: con balena; tratteggio: soglia. Più le due distribuzioni sono separate, meglio funziona la rete; la zona sovrapposta contiene gli errori.

Metriche indipendenti dalla soglia

Curva ROC e ROC-AUC (metrica principale)

Cosa fa: prova tutte le soglie possibili e per ognuna disegna un punto con:

Asse	Valore
Verticale	tasso di veri positivi = recall
Orizzontale	tasso di falsi positivi = 1 − specificità

Il caso è la diagonale. Una buona rete sale subito verso l'alto a sinistra.

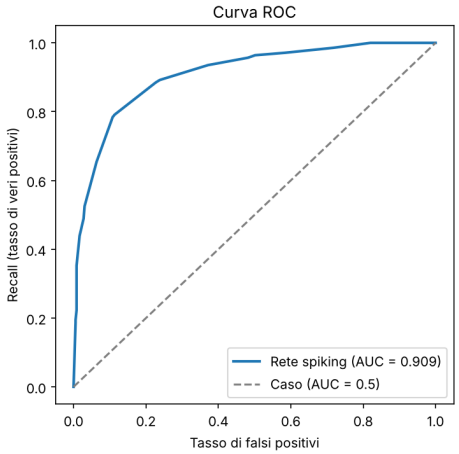


Figura 3 · roc.png

> ROC-AUC = probabilità che un clip con balena preso a caso riceva un punteggio più alto di un clip senza balena preso a caso

Esempio: AUC = 0,909, cioè nel 91% delle coppie il clip con balena viene messo davanti.

Perché è la principale: non dipende dalla soglia, non risente dello sbilanciamento ed è la metrica usata nelle competizioni sui versi di balena, quindi permette confronti.

ROC-AUC	Lettura indicativa
0,50	caso, la rete non ha imparato
0,50 – 0,70	debole
0,70 – 0,80	discreta
0,80 – 0,90	buona
oltre 0,90	ottima
sotto 0,50	peggio del caso, di solito etichette invertite

Le fasce sono solo orientative: dipendono da quanto sono difficili i dati, per questo serve il confronto con un baseline.

Curva Precision-Recall e PR-AUC (average precision)

Cosa fa: come la ROC, ma con precision e recall sugli assi. Mette in evidenza i falsi allarmi quando le balene sono rare.

Riferimento del caso: non 0,5 ma la quota di balene nel test set, qui 139 / 500 = 0,28.

Esempio: AP = 0,793 contro un caso di 0,28.

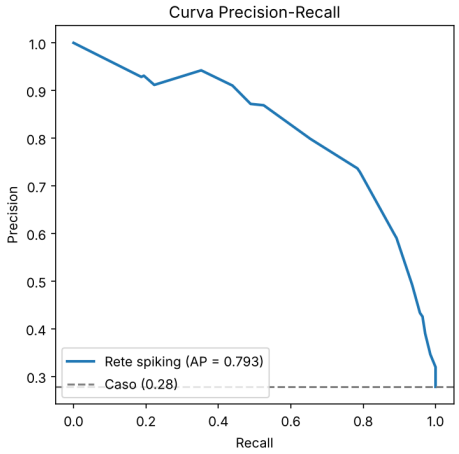


Figura 4 · precision_recall.png

Affidabilità dei risultati

Intervallo di confidenza al 95% (bootstrap)

Il test set è un campione: con altri clip la AUC sarebbe un po' diversa. Lo script ricampiona il test set 1000 volte (pescando i clip a caso con ripetizione), ricalcola ogni volta la AUC e prende l'intervallo che contiene il 95% dei valori.

> ROC-AUC = 0,909, IC 95%: **0,879 – 0,936**

Se l'intervallo contiene 0,5, la rete non è distinguibile dal caso. Se gli intervalli di due modelli si sovrappongono molto, la differenza può essere fortuna.

Più addestramenti con seed diversi

L'addestramento parte da pesi casuali, quindi seed diversi danno reti leggermente diverse. Si addestra 3–5 volte e si riporta media ± deviazione standard (es. AUC = 0,905 ± 0,008). Nello script: `--aggregate`. Deviazione standard piccola = risultato stabile.

Quando il risultato è buono

Confronti da fare sugli stessi dati e con la stessa divisione:

Confronto	Verifica	Condizione
Caso (AUC 0,5)	La rete ha imparato?	IC 95% della AUC tutto sopra 0,5
Risposta sempre "no"	L'accuracy è significativa?	Accuracy sopra la quota di clip senza balena
Modello semplice (es. regressione logistica)	Serve una rete spiking?	La rete spiking deve superarlo
Rete classica (es. CNN)	Distanza dallo stato dell'arte	Entro pochi punti di AUC = buon risultato

Verdetto automatico dello script: controlla il caso, la risposta sempre "no" e, con `--baseline-auc`, il baseline ("supera", "vicina" entro 0,03, "sotto"). Segnala anche molti clip senza spike in uscita (neuroni che non sparano mai).

Spike medi per clip

Numero medio di spike in uscita per clip (qui 5,4). Non misura la qualità del riconoscimento ma l'attività della rete: a parità di AUC, meno spike = meno energia, il vantaggio tipico delle reti spiking.

Riepilogo

Metrica	Cosa dice	Esempio	Dipende dalla soglia
ROC-AUC	Quanto bene ordina balene e non balene	0,909	No
IC 95% AUC	Incertezza della AUC	0,879–0,936	No
PR-AUC (AP)	Qualità sulla classe rara	0,793	No
Accuracy	Risposte giuste sul totale	0,860	Sì
Balanced accuracy	Risposte giuste, classi pesate uguale	0,839	Sì
Recall	Balene trovate	0,791	Sì
Precision	Allarmi corretti	0,728	Sì
Specificità	Clip vuoti riconosciuti	0,886	Sì
F1	Equilibrio precision / recall	0,759	Sì
F0.5	Come F1, più peso alla precision	0,740	Sì
F2	Come F1, più peso alla recall	0,778	Sì
Spike medi per clip	Attività della rete	5,4	No

Ordine di lettura: ROC-AUC con il suo intervallo (la rete funziona?), poi recall e precision (che errori fa?), poi i baseline (è buona?).

File prodotti dallo script

File	Contenuto
metrics.json	Tutte le metriche, la soglia e il verdetto
predictions.csv	Una riga per clip: etichetta, punteggio, risposta, spike dei due neuroni (per riascoltare i clip sbagliati)
confusion_matrix.png	Figura 1
score_distribution.png	Figura 2
roc.png	Figura 3
precision_recall.png	Figura 4